


Cours par Mohamad Forouzanfar

L'IA DANS LES SOINS DE SANTÉ

GTS880

Sujets spéciaux en technologies de la santé



Cours 6

TRAITEMENT DES SIGNAUX PHYSIOLOGIQUES POUR L'APPRENTISSAGE AUTOMATIQUE

Rappel

LA DATE LIMITE POUR CHOISIR L'ARTICLE DU PROJET FINAL EST LE **VENDREDI 10 OCTOBRE**.


L'EXAMEN INTRA AURA LIEU LE **22 OCTOBRE**

Objectifs

- Apprendre les éléments d'un instrument biomédical
- Apprendre la représentation fréquentielle des biosignaux
- Comprendre comment échantillonner ou rééchantillonner les biosignaux pour les applications ML/DL
- Se familiariser avec les techniques de filtrage pour supprimer les artefacts indésirables
- Alignement des données

PRÉPARATION DES DONNÉES

ML/DL



Un MLP profond avec de nombreuses couches cachées (>2) est classé dans la classe des algorithmes DL.

Les progrès récents en matière de puissance de calcul (par exemple, les GPU rapides) et d'algorithmes d'optimisation ont permis de développer des MLP plus profonds.

MLP profond

- **MLP peu profond pour les tâches de base** : Les MLP avec très peu de couches cachées (souvent une ou deux) sont couramment utilisés pour les tâches de régression et de classification standard où l'espace des caractéristiques ne nécessite pas de représentations hiérarchiques complexes.
- **MLP profond pour l'extraction de caractéristiques** : L'une des principales caractéristiques des MLP profonds (plusieurs couches cachées) est leur capacité à apprendre des représentations hiérarchiques des données d'entrée. Les premières couches apprennent des caractéristiques de bas niveau, et les couches suivantes les combinent pour former des caractéristiques de plus en plus abstraites et complexes. Les couches ultérieures utilisent les caractéristiques apprises pour effectuer la régression ou la classification finale.

Pourquoi les algorithmes ML conventionnels sont sensibles au prétraitement des données?

Parce qu'ils ont peu de paramètres et ne peuvent pas extraire seuls les bonnes caractéristiques, donc ils dépendent du prétraitement — contrairement au deep learning qui les apprend automatiquement.



Quelques étapes de prétraitement qui peuvent contribuer à améliorer les performances :


- Rééchantillonnage (Cours 6) : réduire la dimension et le surajustement
- Suppression du bruit et des artefacts (Cours 6) : réduire le surajustement
- Supprimer les données redondantes/non pertinentes (Cours 8) : réduire le surajustement
- Extraction de caractéristiques (Cours 8) : simplifier et réduire la dimension
- Mise à l'échelle et normalisation (Cours 4) : équilibrer l'influence des variables
- Augmentation des données (Cours 4) : améliorer la généralisation
- Alignement spatio-temporel (Cours 6) : synchroniser pour de meilleur apprentissage

Le bon régime de données pour les algorithmes d'apprentissage automatique

- Les modèles d'apprentissage automatique sont généralement plus performants lorsque les données sont traitées de manière appropriée.
- Les algorithmes ML conventionnels sont particulièrement sensibles au prétraitement des données.
- Les modèles DL, s'ils disposent d'un nombre suffisant d'exemples d'entrées/sorties (bien que cela ne soit pas toujours pratique) et s'ils sont conçus correctement, tendent à être moins dépendants du prétraitement des données.

Technique	Rôle Nécessaire
Rééchantillonnage (Signal)	Pour modifier la résolution ou réduire la dimension (taille) des données brutes, ce qui mène à moins de paramètres et réduit le surapprentissage.
Suppression du bruit et des artefacts	Pour améliorer la qualité des données et forcer le modèle à apprendre les motifs réels, ce qui réduit le surapprentissage.
Supprimer les données redondantes ou non pertinentes	Pour simplifier le modèle, réduire le temps d'entraînement et éviter le surapprentissage causé par le bruit.
Extraction de caractéristiques	Pour créer de nouvelles variables informatives à partir des données brutes et améliorer les performances du modèle.
Mise à l'échelle et normalisation	Pour accélérer la convergence de l'optimiseur et assurer un poids égal à toutes les caractéristiques.
Augmentation des données	Pour augmenter la taille et la diversité du jeu, ce qui améliore la généralisation du modèle.
Alignement spatio-temporel	Pour synchroniser les données et assurer leur comparabilité à travers le temps ou l'espace.

Le bon régime de données
pour les algorithmes
d'apprentissage automatique



Signaux physiologiques

Cours 1-2 :
Caractérisation des
fonctions du corps
humain

Cours 1-2 :
Génération de
biosignaux

Cours 1-2 : Mesure
des signaux
biologiques

Cours 6 :
Instruments
biomédicaux

Traitement et préparation

Cours 6 :
Numérisation,
échantillonnage

Cours 4:
Équilibrage des
classes

Cours 6 : Filtres
numériques

Cours 6 :
Alignement des
données

Cours 4 :
Augmentation

Cours 4 :
Normalisation

Réseaux neuronaux

Cours 3 : MLP

Cours 5 : RNN,
LSTM

Cours 9-10 :
CNN

Cours 5 :
Transformers

Entraînement et validation

Cours 3 :
OLS

Cours 3 :
GD, Momentum
RMSPROP,
Adam

Cours 3 :
Rétropropagation

Cours 3 :
Apprentissage par
instance, par
mini-batch, par
batch

Cours 4 :
Optimisation du
modèle et
sélection des
hyperparamètres

Cours 4 :
Arrêt précoce/
Dropout/
normalisation par
lot

Évaluation des performances

Cours 4 :
ME/SDE/MAE/
MAP

Cours 4 :
Coefficient de
correlation/ BA
Plot

Cours 4 :
ACC, SEN,
SPEC, F1, AUC

Ingénierie des caractéristiques

Cours 8 :
Extraction de
caractéristiques

Cours 8 :
Sélection de
caractéristiques

Cours 8 :
Réduction de
caractéristiques

Apprentissage automatique classique

Cours 3 :
Régression
linéaire

Cours 5 : MA,
AR, ARMA

Cours 11 : SVM

Cours 11 : KNN

Cours 11 :
classificateur
bayésien

Cours 11 :
Regroupement

Cours 11 :
K-Means

INSTRUMENTS BIOMÉDICAUX

Éléments des instruments biomédicaux

Capteur : électrodes, capteur de pression, etc.

Interface du capteur : préamplificateur, circuit de polarisation, etc.


Conditionnement du signal : filtre, amplificateur, etc.

Numérisation : convertisseur analogique-numérique (ADC)

Isolation : optocoupleur, inductif, etc.

Analyse : traitement des données (hors ligne ou en ligne), y compris le prétraitement, le traitement des signaux et les modèles ML/DL.

Actionneur : électrique, mécanique, acoustique, retour d'information à l'utilisateur, etc.




Éléments des instruments biomédicaux


Éléments des instruments biomédicaux

Applications de l'Analyse de Signaux dans des Systèmes de Rétroaction

- CPAP/Apnée du sommeil : Mesurer les signaux physiologiques pour détecter l'arrêt de la respiration et ajuster la pression de la machine (CPAP).
- Amélioration du sommeil : Analyser les signaux cérébraux (EEG) pour diffuser des bruits acoustiques brefs afin d'augmenter le sommeil profond.
- Gestion du stress : Utiliser la stimulation du nerf vague (neuromodulation) pour moduler et réduire le niveau de stress.



Éléments des instruments biomédicaux



Exemple : Neuromodulation non invasive du stress

- **Objectif :** Appliquer la stimulation non invasive du nerf vague (nVNS) pour moduler les réponses sympathiques au stress psychologique chez les personnes souffrant de troubles du système nerveux central, tels que le syndrome de stress post-traumatique (PTSD).

Principales Etapes :

- 1- Enregistrement des signaux physiologiques,
- 2- Extraction des caractéristiques,
- 3- Détection du stress à partir des signaux enregistrés,
- 4- Application des stimulations du nerf vague selon les besoins.


ANALYSE DE FRÉQUENCE

Transformée de Fourier : Réexamen

La Transformée de Fourier (FT) d'un signal est obtenue en mesurant sa similarité avec des fonctions de base sinusoïdales (sinus et cosinus) à différentes fréquences. Le degré de cette similarité indique la quantité de chaque fréquence présente dans le signal : plus la similarité est élevée, plus la composante fréquentielle correspondante est importante, ce qui se traduit par une magnitude plus élevée dans la FT.

Cette similarité peut être mesurée à l'aide d'un **produit scalaire** entre le signal et la fonction de base. Chaque échantillon du signal est multiplié par l'échantillon correspondant de la fonction de base, puis les résultats sont additionnés.

Plus le produit scalaire est élevé, plus la similarité est grande, et plus la composante fréquentielle correspondante est présente dans le signal.



Un signal dans le domaine temporel (en bleu) décomposé en différentes composantes de fréquence.

Les composantes fréquentielles, réparties sur le spectre de fréquences, sont représentées par de petits cercles dans le domaine fréquentiel.

Au lieu des fonctions sinus ou cosinus, nous utilisons des exponentielles complexes pour simplifier les calculs mathématiques.

Transformée de Fourier : Réexamen

La Transformée de Fourier en temps discret (DTFT) peut être interprétée comme un produit scalaire $\langle \cdot, \cdot \rangle$ entre un signal discret $x[n]$ et un ensemble de fonctions de base exponentielles complexes $e^{-j(2\pi f)n}$.


$$X(f) = \sum_{n=-\infty}^{\infty} x[n] e^{-j(2\pi f)n} = \langle \mathbf{x}, \mathbf{e}_w \rangle$$

où $\mathbf{x} = [\dots, x[-1], x[0], x[1], \dots]^T$ est le vecteur des échantillons du signal dans le domaine temporel (ou spatial), et $\mathbf{e}_w = [\dots, e^{-j(2\pi f)(-1)}, e^{-j(2\pi f)(0)}, e^{-j(2\pi f)(1)}, \dots]$ est le vecteur des échantillons de la fonction de base correspondant à une exponentielle complexe de fréquence f .


Attention : chaque fonction de base représente une composante de fréquence unique.

La transformée $X(f)$ est une fonction de la fréquence f (Hz), représentant la contribution (ou l'intensité) de chaque composante fréquentielle du signal.

Il peut être montré que la transformée de Fourier d'un signal échantillonné (signal discret en temps) est une répétition périodique de la transformée de Fourier du signal continu d'origine, avec une période en fréquence de $f_s = 1/T$ (la fréquence d'échantillonnage)




Puisque la DTFT est périodique et symétrique (autour de 0), on ne conserve que la moitié d'une période (de 0 à $f_s/2$) pour l'analyse.



Houston, Jessica P., et al. "Capture of fluorescence decay times by flow cytometry." *Current protocols in cytometry* 59.1 (2012): 1-25.

Exemple


Transformée de Fourier de
signaux de fréquences différentes



Exercice 1

- Nous voulons calculer la transformée de Fourier d'un segment de signal PPG de 120 secondes.
- **Question : Tracez un spectre de fréquence approximatif de ce signal PPG en tenant compte du contenu de la fréquence principale.**

Transformée de Fourier d'un signal PPG




Exercice

- L'application de la transformée de Fourier à un signal PPG révèle les composantes de fréquence qui constituent la forme d'onde complexe.
- Le PPG est périodique avec ~ 146 cycles en 120 secondes, c'est-à-dire que la fréquence fondamentale est de $146/120 = 1,22$ Hz.
- Harmoniques : Vous pouvez également observer des pics plus petits à des fréquences qui sont des multiples de la fréquence fondamentale. Ces harmoniques sont dues à la forme non sinusoïdale de l'onde PPG.
- L'activité respiratoire peut introduire des variations de basse fréquence dans le signal PPG. Bien qu'il soit moins important que le pic de fréquence cardiaque.
- Nous traçons généralement la magnitude du FT et l'échelonons en unités de décibels (dB) :

$$10\log(|FT|)$$

où le logarithme est en base 10.



$$f_s - f_{max} > f_{max} \Rightarrow f_s > 2 \times f_{max}$$

La condition $f_s \geq 2f_{max}$ est appelée condition de **Nyquist** ; si elle n'est pas respectée, le signal subit un repliement spectral, appelé **aliasing**, et ne peut pas être correctement reconstruit.

Théorème d'échantillonnage

Numérisation : Conversion analogique-numérique

On peut démontrer que l'échantillonnage d'un signal $x(t)$ aux instants $t=nT$, c'est-à-dire:

$$x[n] = x(nT)$$

est équivalent, dans le domaine fréquentiel, à une répétition périodique de la transformée de Fourier du signal continu d'origine, avec une période égale à la fréquence d'échantillonnage $f_s = 1/T$.

Question : Quel intervalle ou quelles valeurs permettront d'obtenir un échantillonnage correct, sans chevauchement des contenus fréquentiels (sans distorsion du contenu fréquentiel) ?


Théorème d'échantillonnage

Sous-échantillonnage des signaux numériques

Le même concept d'échantillonnage de signaux continus en signaux discrets s'applique au rééchantillonnage de signaux discrets à des taux d'échantillonnage inférieurs.

Si le **nouveau taux d'échantillonnage** est inférieur à $2 \times f_{\max}$, un repliement (aliasing) se produit.

Il est donc très important de s'assurer que la nouvelle fréquence d'échantillonnage est toujours **supérieure à la fréquence de Nyquist** : $2 \times f_{\max}$.




Le sous-échantillonnage en fréquence.

(a) Spectre du signal original $x(n)$ échantillonné à f_s Hz.

(b) $x(n)$ sous-échantillonné d'un facteur 2 ($f_{s_new} = f_s/2$).

(c) $x(n)$ sous-échantillonné d'un facteur 3 ($f_{s_new} = f_s/3$).

(d) $x(n)$ sous-échantillonné d'un facteur M ($f_{s_new} = f_s/M$).



<https://en.wikipedia.org/wiki/Aliasing#/media/File:Aliasing.gif>

Démonstration de l'aliasing dans le domaine temporel

Illustration de 4 formes d'onde reconstruites à partir d'échantillons prélevés à six fréquences différentes. Deux des formes d'onde ont un contenu en fréquences plus faible et ne sont donc pas affectées. Les deux autres illustrent une distorsion croissante (aliasing) aux fréquences d'échantillonnage les plus basses.



Théorème d'échantillonnage

Sous-échantillonnage des signaux numériques



Les signaux physiologiques sont généralement échantillonnés à des taux d'échantillonnage élevés, ce qui conduit à des informations redondantes.

Pour la plupart des applications de ML, nous n'avons pas besoin de tous ces détails à haute résolution. Par conséquent, il est souhaitable de les sous-échantillonner à un taux inférieur (Pour réduire la dimension des données brutes, ce qui mène à moins de paramètres et réduit le surapprentissage).

Pour réduire l'échantillonnage d'un signal, il est nécessaire d'appliquer d'abord un **filtre passe-bas (low-pass filter)** afin d'éliminer toute composante haute fréquence indésirable susceptible de provoquer un repliement.



(a) Down-sampling without anti-aliasing



(b) Down-sampling with anti-aliasing

Rééchantillonnage. (a) Lors du sous-échantillonnage d'un signal dont la fréquence d'échantillonnage est inadéquate, le problème du repliement déforme le spectre de fréquences du signal original. (b) Le repliement peut être atténué par l'intégration d'un filtre passe-bas avant le sous-échantillonnage. Le filtre passe-bas atténue la bande de haute fréquence et inhibe ainsi le repliement de la bande de haute fréquence.

Théorème d'échantillonnage

Sous-échantillonnage des signaux numériques

Exercice 2: Pouvez-vous indiquer quelles fréquences devraient être supprimées en utilisant le filtre passe-bas (fréquence de coupure du filtre) ?

- fréquence maximale du signal : $f_{\max}$
- nouvelle fréquence d'échantillonnage : f_{new}



Réponse :

Basé sur le théorème de Nyquist :



$$f_{\text{new}} > 2 f_{\max}$$

➔ $f_{\max} < f_{\text{new}} / 2$

➔ la fréquence de coupure du filtre doit être $f_{\text{new}}/2$



(a) Down-sampling without anti-aliasing



(b) Down-sampling with anti-aliasing

Rééchantillonnage. (a) Lors du sous-échantillonnage d'un signal dont la fréquence d'échantillonnage est inadéquate, le problème du repliement déforme le spectre de fréquences du signal original. (b) Le repliement peut être atténué par l'intégration d'un filtre passe-bas avant le sous-échantillonnage. Le filtre passe-bas atténue la bande de haute fréquence et inhibe ainsi le repliement de la bande de haute fréquence.

Jin, Cece, et al. "Low Pass Filter for Anti-aliasing in Temporal Action Localization." *arXiv preprint arXiv:2104.11403* (2021).

Théorème d'échantillonnage

Sous-échantillonnage des signaux numériques

La réduction du taux d'échantillonnage (sous-échantillonnage) **par un facteur entier M** peut être expliquée comme un processus en deux étapes :

1. Supprimer les composantes haute fréquence du signal à l'aide d'un filtre passe-bas numérique afin d'éviter l'aliasing.
2. Décimer le signal filtré par M , c'est-à-dire ne conserver que chaque échantillon M .


Exemple :

Sous-échantillonnage d'un signal EEG de 128 Hz à 32 Hz :

Facteur d'échantillonnage $M = 128/32 = 4$

Fréquence de coupure du filtre passe-bas $32/2 = 16$ Hz

Décimation : conserver 1 échantillon temporel EEG sur $M = 4$



Théorème d'échantillonnage

Sous-échantillonnage des signaux numériques

Réduction du taux d'échantillonnage (sous-échantillonnage) par un facteur non entier M/L (M n'est pas un multiple de L) :

Soit M/L le facteur de décimation, où : M, L sont des entiers positifs avec $M > L$:

1. Augmenter (rééchantillonner) la séquence d'un facteur L . (ceci est appelé suréchantillonnage) suivi d'une interpolation (ajouter $L-1$ zéros entre chaque paire d'échantillons temporels).
2. Sous-échantillonner d'un facteur M

Exemple :

Sous-échantillonnage d'un signal EEG de 128 Hz à 15 Hz :

Facteur d'échantillonnage $M/L = 128/15$

1. Suréchantillonnage et décimation

- Suréchantillonner par un facteur 15, c'est-à-dire ajouter $15-1=14$ zéros entre chaque paire d'échantillons temporels.

2. Sous-échantillonnage

- Filtre passe-bas anti-aliasing avec une coupure de $15/2 = 7.5$ Hz (doit être un nombre entier)
- Décimer par un facteur de 128 (conserver 1 échantillon temporel sur 128).

Filtres numériques

Représentation temporelle

Un filtre est une opération qui modifie le contenu spectral d'un signal. Dans le temps, la forme d'onde de sortie $y(t)$ peut être considérée comme une somme pondérée de plusieurs échantillons du signal d'entrée $x(t)$, qui est généralement représenté comme une convolution :

$$y(t) = x(t) * h(t)$$

$$= \sum_{n=1}^d h(n)x(t-n)$$

où t est le point d'analyse dans le temps et $h(n)$; $n = 0, \dots, N$ est la réponse impulsionnelle du filtre.

Exercice 3 :


Représentez le filtrage par l'opération du produit scalaire au lieu de la convolution.

$$\mathbf{h} = [h(1), h(2), \dots, h(d)]^T$$

$$\mathbf{x}_r(t) = [x(t-1), x(t-2), \dots, x(t-d)]^T$$

$$\mathbf{y}(t) = \langle \mathbf{h} \cdot \mathbf{x}_r(t) \rangle$$

En pratique, nous retournons le filtre au lieu du signal (Mais, les deux sont corrects).



Concept de filtrage dans le temps à l'aide de la convolution :

La convolution implique de faire glisser un filtre (ou noyau) retourné dans le temps sur un signal, en multipliant les valeurs superposées à chaque position, et en sommant ces produits pour obtenir la sortie à cet instant.

Filtres numériques


Exercice 2

1. Un signal EEG a été filtré à l'aide de deux filtres distincts. Quelles sont les différences potentielles entre les signaux filtrés résultants ? Expliquez.
2. Voici les coefficients temporels de deux filtres. En vous basant sur les signaux filtrés fournis, quel filtre a produit quel signal filtré ? Justifiez votre réponse.


$$\mathbf{h} = [1, 1, \dots, 1]_{(15 \times 1)}^T$$

$$\mathbf{h} = [-1, 1]_{(2 \times 1)}^T$$


Signal EEG de 30 secondes pendant le sommeil



Signal EEG filtré 1 Le filtre de moyennage $\mathbf{h} = [1, 1, \dots, 1]_{15 \times 1}^T$



Signal EEG filtré 2 Le filtre de différenciation $\mathbf{h} = [-1, 1]_{2 \times 1}^T$



Filtres numériques


Représentation fréquentielle

Dans le domaine des fréquences, la convolution devient une multiplication et le filtrage peut donc être facilement représenté comme le produit du signal et du noyau du filtre :

$$Y(F) = X(F) H(F)$$

Types de filtres :

- Le filtre passe-bas atténue les hautes fréquences
- Le filtre passe-haut atténue les basses fréquences
- Le filtre passe-bande atténue les fréquences hors bande.
- Le filtre coupe-bande atténue une bande étroite de fréquences.



Les filtres peuvent être représentés de deux façons :

- dans le domaine fréquentiel, par leur réponse en magnitude (en haut),
- dans le domaine temporel, par leurs coefficients du filtre dans le temps (en bas).

Plus la transition est abrupte dans le domaine fréquentiel, plus les coefficients temporels du filtre s'étendent dans le temps (courbe rouge). La raideur de cette transition dépend du type et de l'ordre du filtre.

de Cheveigné, Alain, and Israel Nelken. "Filters: when, why, and how (not) to use them." *Neuron* 102.2 (2019): 280-293.

La raison pour laquelle nous utilisons la convolution plutôt qu'une simple somme pondérée est que la convolution en fréquence se transforme en multiplications, ce qui simplifie nos calculs mathématiques.

Supprimer les tendances des signaux physiologiques

La plupart des biosignaux présentent une composante indésirable de basse fréquence, également appelée « tendance » ou « trend ».

Origine de la tendance



La tendance peut n'être qu'une dérive de la ligne de base due au déplacement des électrodes ou peut refléter des processus physiologiques indésirables à basse fréquence (tels que la respiration, la transpiration, etc.).

Impact sur l'apprentissage automatique

Dans la plupart des applications, la tendance est une composante indésirable, et son élimination permet à l'algorithme d'apprentissage automatique de mieux apprendre la relation entrée-sortie souhaitée (éviter le surapprentissage).

Méthode de suppression de la tendance

Un filtre passe-haut est généralement utilisé pour supprimer cette tendance du signal.



Un signal ECG avec une tendance et sa version détendancée en utilisant un filtre passe-haut de Butterworth avec une fréquence de coupure de 0.5 Hz et un ordre de 4.

Suppression des bruits de haute fréquence

La plupart des biosignaux sont affectés par du bruit et des artéfacts.

Sources courantes de bruit et d'artéfacts



Les bruits courants incluent le bruit de la ligne électrique (50-60 Hz) et les interférences provenant d'autres dispositifs électroniques.

Importance de la suppression des perturbations

Dans la plupart des applications, le bruit et les artéfacts sont des composantes indésirables, et leur suppression permet à l'algorithme d'apprentissage automatique de mieux apprendre la relation entrée-sortie souhaitée (éviter le surapprentissage).

Méthode de suppression du bruit

Un filtre passe-bas est généralement utilisé pour supprimer le bruit et les artéfacts dans les signaux.



Signal ECG bruité et sa version filtrée en passe-bas à l'aide d'un filtre de Butterworth d'ordre 2 avec une fréquence de coupure de 20 Hz.



Basu, S., & Mamud, S. (2020, September). Comparative Study on the Effect of Order and Cut off Frequency of Butterworth Low Pass Filter for Removal of Noise in ECG Signal. In 2020 IEEE 1st International Conference for Convergence in Engineering (ICCE) (pp. 156-160). IEEE.

Alignement des données


Nos séries temporelles physiologiques proviennent d'activités internes qui ne se produisent pas toujours au même moment ni au même rythme, d'où la nécessité d'un alignement pour le ML. Celui-ci assure qu'une caractéristique représente le même événement biologique dans différents enregistrements (différents exemples de données), améliorant l'efficacité du modèle et réduisant la taille de données requise.

Si l'entrée est un vecteur de caractéristiques extraites d'un signal, chaque caractéristique correspond toujours au même phénomène, ce qui garantit l'alignement des données.


Avec des données brutes, l'alignement pose généralement problème. Sans alignement explicite, le modèle a besoin de plus de données et d'un réseau plus complexe pour apprendre et gérer ces désalignements temporels.



Vecteur de caractéristiques pour une observation (exemple de données)



Observation (exemple d'entraînement) 1





Observation (exemple d'entraînement) 2

...

Option 1 : Les données sont alignées.


Diviser chaque segment en cycles cardiaques. Chaque cycle cardiaque sera considéré comme un exemple d'apprentissage. Les caractéristiques morphologiques extraites de chaque cycle cardiaque seront transmises à l'algorithme ML/DL. En supposant que chaque segment comporte environ 5 cycles cardiaques, nos exemples d'entraînement seront $5 \times 100 = 500$.




Feature of the first training sample 1•

Détection des maladies cardiovasculaires à partir de l'ECG

Supposons que nous disposions de 100 segments (100 exemples d'apprentissage) de signaux ECG, chacun portant une étiquette de 0 ou 1 correspondant à un sujet sain ou malade.



Observation (exemple d'entraînement) 1




Observation (exemple d'entraînement) 2

...


Option 2 : Les données sont alignées

Chaque segment est transmis au ML/D à l'aide de caractéristiques extraites. Il peut s'agir, par exemple, de caractéristiques morphologiques extraites de cycles individuels empilés dans le même vecteur de caractéristiques, ou de caractéristiques statistiques telles que la moyenne, l'écart-type, l'entropie, etc. Dans ce cas, le nombre d'exemples d'entraînement est de 100.



Détection des maladies cardiovasculaires à partir de l'ECG

Supposons que nous disposions de 100 segments (100 exemples d'apprentissage) de signaux ECG, chacun portant une étiquette de 0 ou 1 correspondant à un sujet sain ou malade.



Observation (exemple d'entraînement) 1




Observation (exemple d'entraînement) 2

...

Option 3 : Les données ne sont pas alignées

Chaque segment brut est échantillonné dans le temps et les échantillons temporels sont transmis au ML/DL. Comme le montrent les exemples, le premier élément du vecteur de caractéristiques pour l'exemple d'apprentissage 1 correspond approximativement au moment où R s'est produit, tandis que le même élément pour l'exemple d'apprentissage 2 correspond au moment où l'onde Q s'est produite. Ainsi, la même caractéristique dans différents exemples de données représentera un événement différent. Dans ce cas, le nombre d'exemples d'apprentissage est de 100.

Dans ce cas, nous aurons besoin d'un modèle plus complexe pour pouvoir apprendre la relation entrée-sortie et, par conséquent, pour entraîner ce modèle, nous aurons besoin d'un plus grand nombre d'exemples d'entraînement.



Détection des maladies cardiovasculaires à partir de l'ECG

Supposons que nous disposions de 100 segments (100 exemples d'apprentissage) de signaux ECG, chacun portant une étiquette de 0 ou 1 correspondant à un sujet sain ou malade.