


Cours par Mohamad Forouzanfar

L'IA DANS LES SOINS DE SANTÉ

GTS880

Sujets spéciaux en technologies de la santé




Cours 10

INGÉNIERIE DES CARACTÉRISTIQUES

Rappel

L'EXAMEN INTRA 2 : SEMAINE 12, LE 26 NOVEMBRE.

PRÉSENTATION DU PROJET : SEMAINE 13, LE 3 DÉCEMBRE



Signaux physiologiques

- Cours 1-2 : Caractérisation des fonctions du corps humain
- Cours 1-2 : Génération de biosignaux
- Cours 1-2 : Mesure des signaux biologiques
- Cours 6 : Instruments biomédicaux

Traitement et préparation

- Cours 6 : Numérisation, échantillonnage
- Cours 6 : Filtres numériques
- Cours 6 : Alignement des données
- Cours 4 : Augmentation
- Cours 4 : Normalisation
- Cours 4 : Équilibrage des classes

Réseaux neuronaux

- Cours 3 : MLP
- Cours 5 : RNN, LSTM
- Cours 5 : Transformers
- Cours 8-9 : CNN

Entraînement et validation

- Cours 3 : OLS
- Cours 3 : GD, Momentum, RMSPROP, Adam
- Cours 3 : Rétropropagation
- Cours 3 : Apprentissage par instance, par mini-batch, par batch
- Cours 4 : Optimisation du modèle et sélection des hyperparamètres
- Cours 4 : Arrêt précoce/ Dropout/ normalisation par lot

Évaluation des performances

- Cours 4 : ME/SDE/MAE/ MAP
- Cours 4 : Coefficient de corrélation/ BA Plot
- Cours 4 : ACC, SEN, SPEC, F1, AUC

Ingénierie des caractéristiques

- Cours 10 : Extraction de caractéristiques
- Cours 10 : Sélection de caractéristiques
- Cours 10 : Réduction de caractéristiques

Apprentissage automatique classique

- Cours 3 : Régression linéaire
- Cours 5 : MA, AR, ARMA
- Cours 11 : Régression logistique
- Cours 11 : KNN
- Cours 11 : SVM
- Cours 11 : classificateur bayésien
- Cours 11 : Regroupement
- Cours 11 : K-Means

Objectifs

- Apprendre différentes techniques d'extraction de caractéristiques pour l'analyse de signaux biomédicaux et la caractérisation de l'état de santé.
- Apprendre à sélectionner les meilleures caractéristiques.
- Apprendre à réduire le nombre de caractéristiques.

Apprentissage automatique :

Données brutes vs extraction de caractéristiques

Types d'Extraction de Caractéristiques (Feature Engineering) :


1. Extraction Automatique (Deep Learning)

Dans cette approche, le modèle apprend lui-même les caractéristiques les plus importantes directement à partir des **données brutes**.

- Exemple (MLP/CNN) : La première couche d'un réseau de neurones (ou les premières couches convolutives d'un CNN) agit comme un extracteur de caractéristiques. Elle transforme les données d'entrée brutes (échantillons de temps de signal, pixels, mots, etc.) en une représentation plus abstraite et informative. Les couches suivantes affinent et combinent ces caractéristiques initiales.

2. Extraction Manuelle (Expertise Domainale)

Les caractéristiques ne sont pas apprises par le modèle, mais calculées par des algorithmes selon des règles définies par un expert. Par exemple, un expert en santé pourrait décider que la moyenne des intervalles R-R et leur variabilité (HRV) sont des caractéristiques importantes à inclure dans un modèle de prédiction des maladies cardiaques. Les calculs sont automatiques, mais la définition des caractéristiques est manuelle.




Flux de travail d'apprentissage automatique pour l'analyse des signaux biomédicaux

Apprentissage automatique :

Données brutes vs extraction de caractéristiques

Exercice 1 : Quels sont les avantages et les inconvénients de l'utilisation des caractéristiques (conçues par des experts) ?



Flux de travail d'apprentissage automatique pour l'analyse des signaux biomédicaux

Représentation du biosignal

Les biosignaux, échantillonnés à haute fréquence, génèrent des séries temporelles complexes et redondantes. Cette haute dimensionnalité est un défi.

Prenons un exemple avec un signal EEG :

- Échantillonnage 1024 Hz : 1024 points de données/seconde.
- Segment d'1 minute : $1024 \times 60 = 61440$ points.
- 16 canaux EEG : $61440 \times 16 = 983040$ points.

➔ Il s'agit de la dimension du vecteur d'entrée : le nombre de caractéristiques.

Simplification des Données

Malgré leur complexité, les biosignaux peuvent souvent être représentés avec moins de points de données (dimension inférieure) sans perte d'information cruciale. Le sous-échantillonnage (downsampling) est une méthode simple pour réduire ce volume de données.



EEG avec pointes épileptiques

@: <https://en.wikipedia.org/wiki/Electroencephalography>


Ingénierie des caractéristiques

Une entrée de haute dimension nous contraint à utiliser des **modèles plus complexes** avec un plus grand nombre de paramètres à optimiser. Cela se traduit directement par :

1. Demandes accrues en ressources : Une mémoire et une puissance de calcul importantes sont nécessaires, ce qui peut être coûteux et chronophage.

2. Défis d'optimisation : Avec de nombreux paramètres inconnus, le processus d'optimisation devient plus difficile. L'algorithme pourrait avoir du mal à trouver la véritable solution optimale et pourrait facilement se bloquer dans un minimum local pendant l'entraînement.

3. Risque de surapprentissage (Exercice 2: Expliquez pourquoi ?) :



<https://bigdataanalyticsnews.com/pros-cons-of-feature-engineering/>


L'ingénierie des caractéristiques transforme les données brutes en **meilleures caractéristiques** pour les modèles d'apprentissage automatique.

Ingénierie des caractéristiques

Extraction de Caractéristiques : *Créer* de nouvelles caractéristiques plus informatives à partir de données brutes complexes pour dégager des motifs.

Réduction de Caractéristiques (Réduction de Dimensionnalité) : *Transformer* un ensemble de caractéristiques existant, souvent redondant, en un ensemble plus petit tout en conservant l'information essentielle.

Sélection de Caractéristiques : *Choisir* le sous-ensemble de caractéristiques les plus pertinentes et influentes pour une tâche donnée.




<https://bigdataanalyticsnews.com/pros-cons-of-feature-engineering/>

L'ingénierie des caractéristiques transforme les données brutes en **meilleures caractéristiques** pour les modèles d'apprentissage automatique.


EXTRACTION DE CARACTÉRISTIQUES

Le signal VAG a été enregistré par un accéléromètre placé sur la rotule (patella) du genou. Le sujet balançait sa jambe sur un angle approximatif de 135° (flexion complète) à 0° (extension complète), puis retournait à 135° en 4 secondes. La première moitié de chaque signal VAG correspond à l'extension, et la seconde moitié correspond à la flexion de la jambe. Les signaux VAG ont été préfiltrés (passe-bande : 10 Hz à 1 kHz) et numérisés à une fréquence d'échantillonnage de 2 kHz.

Signal VAG de (a) un sujet normal et (b) un sujet présentant une pathologie de l'articulation du genou.



(a)



(b)

Problème

Analyser le signal du vibroarthrogramme (VAG)

Extraire des caractéristiques simples qui peuvent caractériser la variabilité du signal pour la classification (normale ou anormale) des signaux VAG.

Le signal VAG anormal présente un degré plus élevé de variation globale, d'activité ou de complexité que le signal normal.

Caractéristiques statistiques

Les caractéristiques statistiques sont clés en analyse de signaux biomédicaux. Elles caractérisent la distribution de probabilité (PDF) du signal, où chaque échantillon de signal est traité comme une observation.

Moyenne (μ_η) : Représente la valeur attendue du signal $\eta(n)$.

Valeur quadratique moyenne (Puissance du signal) (**MS_η**) : Indique la "puissance" ou l'intensité globale du signal.

Variance (σ_η^2) : Mesure la dispersion des valeurs du signal autour de sa moyenne. Son écart-type (σ) est sa racine carrée.

Asymétrie (Skewness) (S_η) : Mesure l'asymétrie de la distribution du signal.

Kurtosis (K_η) : Mesure l'« épaisseur des queues » et le « degré de piquant » de la distribution.

Entropie (H_η) : Mesure l'information, le désordre ou l'incertitude dans le signal.

Pour un signal discret $\eta(n)$ à N échantillons et avec un nombre fini L de valeurs discrètes (ou quantifiées) η_l :

$$\mu_\eta = \frac{1}{N} \sum_{n=0}^{N-1} \eta(n)$$

$$MS_\eta = \frac{1}{N} \sum_{n=0}^{N-1} [\eta(n)]^2$$

$$\sigma_\eta = \sqrt{\frac{1}{N} \sum_{n=0}^{N-1} [\eta(n) - \mu_\eta]^2}$$

$$S_\eta = \frac{1}{N} \sum_{n=0}^{N-1} \left(\frac{\eta(n) - \mu_\eta}{\sigma_\eta} \right)^3$$

$$K_\eta = \frac{1}{N} \sum_{n=0}^{N-1} \left(\frac{\eta(n) - \mu_\eta}{\sigma_\eta} \right)^4$$

$$H_\eta = - \sum_{l=0}^{L-1} p_\eta(\eta_l) \log_2[p_\eta(\eta_l)]$$

D'après les données, on observe que le signal anormal présente un degré plus élevé de variation globale, d'activité ou de complexité que le signal normal.


Les mesures statistiques, notamment l'asymétrie, la courbure et l'entropie, peuvent fournir de bonnes performances pour distinguer les signaux VAG normaux et anormaux.

Avec une base de données de 89 signaux VAG, une efficacité de filtrage allant jusqu'à **0,82** a été obtenue, en termes de surface sous la courbe des caractéristiques de fonctionnement du récepteur (**ROC**), à l'aide d'un classificateur de réseau neuronal.


Problème

Analyser le signal du vibroarthrogramme (VAG)

Extraire des caractéristiques simples qui peuvent caractériser la variabilité du signal pour la classification (normale ou anormale) des signaux VAG.



Les signaux présentant des schémas complexes tels que l'EMG et le PCG (et bien sûr d'autres signaux biomédicaux) peuvent ne pas permettre une analyse directe de leur forme d'onde.



Signal PCG d'un individu sain (23 ans) et d'un patient (14 mois) présentant un souffle (murmur) systolique (environ 0,1 – 0,28 s), un dédoublement de S2 (0,28 – 0,38 s) et un claquement d'ouverture mitrale (0,38 – 0,43 s).

Problème

Analyser l'étendue de la variabilité des signaux tels que le PCG et l'EMG

Extraire les caractéristiques qui représentent l'activité et la complexité du signal et les utiliser pour classer différents modèles d'activité (dans le cas de l'EMG) et les modèles sains et malades (dans le cas du PCG).

Mesures d'activité

Zero crossing rate (taux de passage par zéro) (ZCR) est le nombre de fois qu'un signal traverse une ligne de référence (comme 0) dans un intervalle donné.

Turn counts (Comptage de changements de pente) représente le nombre de changements de pente d'un signal.


L'enveloppe d'un signal délimite ses valeurs maximales et minimales, souvent utilisée pour représenter l'amplitude d'un signal au fil du temps.

La mobilité est la racine carrée du ratio de la variance de la première dérivée du signal sur la variance du signal (original).


$$M_x = \left[\frac{\sigma_{x'}^2}{\sigma_x^2} \right]^{\frac{1}{2}} = \frac{\sigma_{x'}}{\sigma_x}$$

La complexité (facteur de forme) (FF) est le ratio de la mobilité de la première dérivée du signal sur la mobilité du signal lui-même.

$$FF = \frac{M_{x'}}{M_x} = \frac{\sigma_{x''}/\sigma_{x'}}{\sigma_{x'}/\sigma_x}$$



Exercice 3 : Combien de PVC avons-nous ici ? Comment détecter un PVC ?



Application

Distinguer les battements
ECG normaux des battements
ectopiques (PVCs)

Les contractions ventriculaires prématurées (PVC), aussi appelées extrasystoles ventriculaires, sont des battements supplémentaires du cœur originaires de l'un des ventricules. Donc, les cellules ventriculaires génèrent une activité électrique avant le nœud SA.


Ces battements anormaux interrompent le rythme cardiaque habituel.

BIOMARQUEURS DES SIGNAUX ECG ET EEG

Biomarqueurs ECG

Des schémas temporels et fréquentiels spécifiques dans les données d'ECG ont été mis en évidence comme corrélant avec diverses pathologies cardiovasculaires, l'état de santé mentale, et d'autres facteurs.

Les schémas temporels les plus élémentaires de l'ECG comprennent la durée et l'amplitude de ses différentes composantes (ou sous-ondes).



García-Gutiérrez, Maria Salud, et al. "Biomarkers in psychiatry: concept, definition, types and relevance to the clinical reality." *Frontiers in psychiatry* 11 (2020): 432.

Feature	Description	Pathology	Duration
P wave	The P wave represents depolarization of the atria. Atrial depolarization spreads from the SA node towards the AV node, and from the right atrium to the left atrium .	The P wave is typically upright in most leads except for aVR; an unusual P wave axis (inverted in other leads) can indicate an ectopic atrial pacemaker . If the P wave is of unusually long duration, it may represent atrial enlargement. Typically a large right atrium gives a tall, peaked P wave while a large left atrium gives a two-humped bifid P wave.	<80 ms
PR interval	The PR interval is measured from the beginning of the P wave to the beginning of the QRS complex. This interval reflects the time the electrical impulse takes to travel from the sinus node through the AV node.	A PR interval shorter than 120 ms suggests that the electrical impulse is bypassing the AV node, as in Wolf-Parkinson-White syndrome . A PR interval consistently longer than 200 ms diagnoses first degree atrioventricular block . The PR segment (the portion of the tracing after the P wave and before the QRS complex) is typically completely flat, but may be depressed in pericarditis .	120 to 200 ms
QRS complex	The QRS complex represents the rapid depolarization of the right and left ventricles. The ventricles have a large muscle mass compared to the atria, so the QRS complex usually has a much larger amplitude than the P wave.	If the QRS complex is wide (longer than 120 ms) it suggests disruption of the heart's conduction system, such as in LBBB , RBBB , or ventricular rhythms such as ventricular tachycardia . Metabolic issues such as severe hyperkalemia , or tricyclic antidepressant overdose can also widen the QRS complex. An unusually tall QRS complex may represent left ventricular hypertrophy while a very low-amplitude QRS complex may represent a pericardial effusion or infiltrative myocardial disease .	80 to 100 ms
J-point	The J-point is the point at which the QRS complex finishes and the ST segment begins.	The J-point may be elevated as a normal variant. The appearance of a separate J wave or Osborn wave at the J-point is pathognomonic of hypothermia or hypercalcemia .	
ST segment	The ST segment connects the QRS complex and the T wave; it represents the period when the ventricles are depolarized.	It is usually isoelectric, but may be depressed or elevated with myocardial infarction or ischemia. ST depression can also be caused by LVH or digoxin . ST elevation can also be caused by pericarditis , Brugada syndrome , or can be a normal variant (J-point elevation).	
T wave	The T wave represents the repolarization of the ventricles. It is generally upright in all leads except aVR and lead V1.	Inverted T waves can be a sign of myocardial ischemia, left ventricular hypertrophy , high intracranial pressure , or metabolic abnormalities. Peaked T waves can be a sign of hyperkalemia or very early myocardial infarction .	160 ms
Corrected QT interval (QTc)	The QT interval is measured from the beginning of the QRS complex to the end of the T wave. Acceptable ranges vary with heart rate, so it must be corrected to the QTc by dividing by the square root of the RR interval.	A prolonged QTc interval is a risk factor for ventricular tachyarrhythmias and sudden death. Long QT can arise as a genetic syndrome , or as a side effect of certain medications. An unusually short QTc can be seen in severe hypercalcemia.	<440 ms
U wave	The U wave is hypothesized to be caused by the repolarization of the interventricular septum. It normally has a low amplitude, and even more often is completely absent.	A very prominent U wave can be a sign of hypokalemia, hypercalcemia or hyperthyroidism.	


Variabilité de la Fréquence Cardiaque (HRV)

Mais qu'est-ce que la HRV ?

La variabilité de la fréquence cardiaque désigne les légères fluctuations temporelles entre nos battements cardiaques.

Ces fluctuations sont indétectables, sauf avec des technologies de surveillance spécialisées (comme l'ECG).

Nous mesurons donc les intervalles RR et étudions leur variabilité au fil du temps.



García-Gutiérrez, Maria Salud, et al. "Biomarkers in psychiatry: concept, definition, types and relevance to the clinical reality." *Frontiers in psychiatry* 11 (2020): 432.





Variabilité de la Fréquence Cardiaque (HRV)

Motifs de HRV normaux et anormaux

Une **HRV structurée** est **plus élevée** est observée chez les individus en bonne santé, tandis que ses motifs anormaux ou des valeurs très faibles peuvent indiquer la présence de problèmes de santé, y compris des affections cardiaques et des problèmes de santé mentale comme l'anxiété et la dépression.

Regardons des motifs de HRV normaux et anormaux.

Exercice 4: Que pensez-vous de l'histogramme de la fréquence cardiaque pour 4 sujets ? Lequel est normal ?



Variabilité de la Fréquence Cardiaque (HRV)


Quelles sont les causes du HRV ?

Les fluctuations de la fréquence cardiaque (HRV) sont médiées par les systèmes nerveux sympathique (SNS) et parasympathique (PNS) par l'intermédiaire du nœud SA du cœur.

Le SNS dirige la réponse involontaire rapide de l'organisme aux situations dangereuses ou stressantes. L'un de ces mécanismes est l'augmentation du rythme cardiaque. Le PNS contrôle les fonctions corporelles au repos, telles que la stimulation de la digestion, l'activation du métabolisme et l'aide à la relaxation. L'un de ces mécanismes est la diminution de la fréquence cardiaque.

Les **fluctuations rapides** de la FC reflètent généralement le contrôle du **SNP** uniquement (le système SNP étant plus rapide que le SNS en raison des neurotransmetteurs spéciaux impliqués).

Les **fluctuations plus lentes** de la FC reflètent la combinaison du **SNS** et du **SNP** + d'autres mécanismes psychologiques et émotionnels.



en caractérisant le motif de la HRV, nous pouvons caractériser les systèmes sympathique et parasympathique

Variabilité de la Fréquence Cardiaque (HRV)

HRV dans le domaine temporel :

SDNN

Écart-type des intervalles **N-N** (*l'intervalle RR après suppression ou correction des battements anormaux*) en ms


rMSSD

Racine carrée de la moyenne des carrés des différences successives des intervalles N-N en ms

pNN50

Pourcentage des différences successives $N-N > 50$ ms
Calculé à partir des différences entre les intervalles N-N successifs

Heart rate variability



$$rMSSD = \sqrt{\frac{1}{N-1} \sum_{i=1}^{N-1} (NN_{i+1} - NN_i)^2}$$


$$pNN50 = \frac{\text{Number of NN intervals where } |NN_{i+1} - NN_i| > 50 \text{ ms}}{N-1} \times 100$$

Variabilité de la Fréquence Cardiaque (HRV)

HRV dans le domaine fréquentiel :

Les bandes de fréquence standard pour l'analyse de la HRV sont généralement :

- Haute fréquence (HF) : de 0,15 à 0,4 Hz (effet de la respiration) (PNS) : *Cette bande reflète principalement l'impact du système nerveux parasympathique (PNS), qui est plus rapide à réagir en raison des neurotransmetteurs spécifiques impliqués.*
- Basse fréquence (LF) : de 0,04 à 0,15 Hz (SNS + PNS) : *Le système sympathique est plus lent que le système parasympathique, mais le système parasympathique a également des composantes lentes.*
- Très basse fréquence (VLF) : de 0,0033 à 0,04 Hz (autres rythmes)



La densité spectrale de puissance (PSD) est le carré de l'amplitude (la puissance) de la transformée de Fourier.



Doudou, M., Bouabdallah, A., & Berge-Cherfaoui, V. (2020). Driver drowsiness measurement technologies: Current research, market solutions, and challenges. *International Journal of Intelligent Transportation Systems Research*, 18(2), 297-319.

Problème

Détection de la somnolence du conducteur

Développer un capteur portable pour détecter la somnolence du conducteur

De nombreux signaux physiologiques tels que l'EEG, l'EMG, l'EOG et l'ECG peuvent être utilisés pour caractériser la somnolence.

Nous examinons ici l'application de l'ECG à cette fin.

Détection de somnolence par HRV

Hypothèse :

- **Somnolence** : HRV **HF** élevée (activation parasympathique).
- **Stress** : HRV **LF** élevée (activation sympathique).
- **Fatigue** : HRV **LF** et **HF** élevée (activation sympathique luttant contre la demande de sommeil parasympathique).
- **Éveillé** : **HF** et **LF** basses.

Étude expérimentale* :


Caractéristiques HRV : Médiane, min et max de la FC (HR), puissances LF et HF, et ratio LF/HF calculés chaque minute.

Classifieur : Linéaire.

Détection de la somnolence : Sensibilité de 0,59 et Spécificité de 0,98.

Caractéristiques les plus importantes : Les caractéristiques du domaine fréquentiel.

Exercice 5: Comment pouvons-nous vérifier l'importance d'une caractéristique ?



Distribution hypothétique des états du sujet en fonction de la puissance de la variabilité de la fréquence cardiaque (HRV) à haute fréquence (HF) et à basse fréquence (LF).


* Vicente, José, et al. "Drowsiness detection using heart rate variability." Medical & biological engineering & computing 54.6 (2016): 927-937.

Biomarqueurs EEG


L'EEG contient diverses bandes de fréquence particulièrement importantes pour caractériser les différents états cérébraux. Les sous-bandes d'intérêt sont :

- **Delta** (0,5–4 Hz) : typique du sommeil profond sans rêves.
- **Thêta** (4–8 Hz) : associé à la somnolence, la méditation et le sommeil léger.
- **Alpha** (8–15 Hz) : présent lors d'un état de relaxation ou d'éveil calme, souvent les yeux fermés.
- **Bêta** (15–30 Hz) : lié à l'éveil, la concentration et l'activité mentale intense.
- **Gamma** (supérieure à 30 Hz) : associé à la conscience, la cognition et les processus de liaison neuronale.

Il a été démontré qu'il existe une relation entre la puissance de ces bandes de fréquence individuelles et diverses conditions des sujets, comme le niveau de déficiences cognitives ou l'intensité du fonctionnement mental du cerveau.



Différentes composantes de l'EEG dans le temps : delta, thêta, alpha, bêta et gamma.
(Wikipedia)



Spectre de puissance (DSP) de l'EEG au repos d'un humain normal.

Namazi, H., & Kulish, V. V. (2012). Mathematical modeling of human brain neuronal activity in the absence of external stimuli. *Journal of Medical Imaging and Health Informatics*, 2(4), 400-407.


SELECTION DE CARACTÉRISTIQUES

Selection de caractéristiques

La **sélection** de caractéristiques choisit un sous-ensemble des caractéristiques existantes. En revanche, **l'extraction** de caractéristiques en crée de nouvelles, soit par des transformations mathématiques (comme la combinaison ou la conversion, par exemple avec les CNN), soit par une définition manuelle par des experts basée sur la connaissance du domaine.

Lors de l'utilisation d'une stratégie de sélection de caractéristiques, l'hypothèse fondamentale est que les données contiennent des caractéristiques qui peuvent être supprimées avec peu ou pas de perte d'informations car elles sont *redondantes* ou *non pertinentes*.


Exercice 6 : Quelle est la différence entre une caractéristique **redondante** et une caractéristique **non pertinente** ?



Selection de caractéristiques

Les méthodes supervisées de sélection de caractéristiques sont classées en trois catégories : les **méthodes de filtre**, les **méthodes wrapper** et les méthodes **intégrées** (ou "embedded").

Un exemple de méthode de sélection de caractéristiques non supervisée est le **seuil de variance** : il supprime toute caractéristique dont la variance sur l'ensemble des données n'atteint pas un seuil spécifié. **La variance est donc considérée comme un marqueur d'information dans cette méthode.**



<https://www.javatpoint.com/feature-selection-techniques-in-machine-learning>

Selection de caractéristiques

Méthodes de filtre

Les **méthodes de filtre** sélectionnent les caractéristiques **indépendamment du modèle d'apprentissage**. Elles évaluent les caractéristiques en se basant sur leurs propriétés intrinsèques, leur similarité et leur relation avec les étiquettes.

Étant donné qu'elles ne nécessitent pas d'entraînement ni de validation croisée du modèle, ces techniques sont particulièrement **efficaces**.


Exemple de méthode filtre : Coefficient de corrélation de Pearson

La corrélation de Pearson mesure la relation linéaire entre deux variables.

En sélection de caractéristiques, une forte corrélation entre une caractéristique et la variable cible indique que cette caractéristique est **importante**.

En revanche, une forte corrélation entre deux caractéristiques révèle une **redondance**, ce qui permet d'en supprimer une.

Le coefficient de corrélation est calculé comme la covariance des variables divisée par le produit de leurs écarts-types.



Le coefficient de corrélation est généralement indiqué par ρ ou r .

Wikipedia


$$r = \frac{\sum_i (x_i - \bar{x}_i)(y_i - \bar{y}_i)}{\sqrt{\sum_i (x_i - \bar{x}_i)^2 \sum_i (y_i - \bar{y}_i)^2}}$$

Selection de caractéristiques

Méthodes de filtre

Tests statistiques :

Les scores statistiques des tests de signification tels que le test du chi carré, le test t, le test F et l'ANOVA peuvent être utilisés pour examiner la différence entre la distribution des caractéristiques..




Les tests statistiques examinent la distribution des caractéristiques et vérifient s'il existe une différence significative entre elles ou non.

Selection de caractéristiques

Méthodes wrapper

Les méthodes wrapper sont des techniques de classement basées sur des modèles qui identifient les caractéristiques les **plus performantes** pour un modèle spécifique.

Nous devons donc tester différents sous-ensembles de caractéristiques et sélectionner le meilleur. ➔ En utilisant un ensemble de validation !



© Jack Tan

<https://towardsdatascience.com/feature-selection-for-machine-learning-in-python-wrapper-methods-2b5e27d2db31>

Selection de caractéristiques

Les méthodes intégrées (embedded)

Les méthodes intégrées sélectionnent les caractéristiques en même temps qu'elles apprennent les paramètres du modèle.

Régression Lasso (régularisation L1)

SOS

$$\text{Minimize} \left[\sum_{i=1}^N (y_i - z_i)^2 + \lambda \sum_{j=1}^d |\alpha_j| \right]$$

Exercice 8 : Expliquez comment cette minimisation nous aidera à sélectionner les caractéristiques les plus importantes ?

il nous permet aussi de réduire le sur-apprentissage

La régression linéaire :

Supposons que nous ayons un ensemble d'observations $\{\mathbf{x}_i\}_{i=1}^N$, le i -ème sortie prédite est modéliser (relation entrée-sortie) comme suit :

$$y_i = \alpha_0 + \alpha_1 x_i(1) + \alpha_2 x_i(2) + \dots + \alpha_d x_i(d)$$

Ce qui peut être reformulé sous forme vectorielle :

$$y_i = \boldsymbol{\alpha}^T \mathbf{x}_i$$

où $\mathbf{x}_i = [1, x_i(1), x_i(2), \dots, x_i(d)]^T$ est le vecteur caractéristique pour l'exemple i , et $\boldsymbol{\alpha} = [\alpha_0, \alpha_1, \alpha_2, \dots, \alpha_d]^T$ est le vecteur des paramètres inconnus (à estimer)

Exercice 7 : Comment trouver les paramètres d'un modèle de régression linéaire : développez une fonction de coût et expliquez comment la minimiser ?

RÉDUCTION DE CARACTÉRISTIQUES

Réduction de caractéristiques

Analyse en composantes principaux (Principal component analysis) (PCA)

Contrairement aux transformations de Fourier ou d'ondelettes (*wavelets*), qui reposent sur des fonctions de base fixes, la **PCA** (une forme de transformation) utilise des fonctions de base optimales dépendant des données.

La PCA peut être représentée comme une projection linéaire des caractéristiques d'origine $\mathbf{x}_{d \times 1}$ à l'aide d'une matrice de projection $\mathbf{A}_{d \times d}$:

$$\mathbf{y} = \mathbf{A}^T \mathbf{x}$$


où les colonnes de la matrice $\mathbf{A}$ sont les fonctions de base.

Comment choisir les fonctions de base ?

SOS

En PCA, nous recherchons de nouvelles directions de projection des données (1) dans lesquelles **la variance est maximale** (en supposant qu'une variance plus élevée signifie une plus grande quantité d'information). Nous supposons également que (2) les fonctions de base sont **orthogonales**, c'est-à-dire que leur produit scalaire est nul. En d'autres termes, elles sont non corrélées (ne partagent aucune information

similaire).




Dans la figure ci-dessus, les fonctions de base sont celles expliquant les axes rouge et vert, c'est-à-dire : $\begin{bmatrix} 1/\sqrt{2} \\ 1/\sqrt{2} \end{bmatrix}$ et

$\begin{bmatrix} -1/\sqrt{2} \\ 1/\sqrt{2} \end{bmatrix}$ (en supposant que les vecteurs sont à $+45^\circ$ et $+135^\circ$).

Remarque : les directions sont normalisées de sorte que leur norme L2 soit égale à un.

Exercice 9 : Calculez le produit scalaire entre les deux directions.



Données

Exercice 10 :
Quelle
projection est la
meilleure ?
Pourquoi ?

Réduction de caractéristiques

Recherche des directions de projection

On peut montrer que les directions de projection (ou « axes principaux ») sont données par les **vecteurs propres de la matrice de covariance des données**.

Le vecteur propre associé à la plus grande valeur propre indique la direction qui capture le plus de variance dans les données.

Comment réduire la dimension ?

On conserve généralement les premières directions de projection qui expliquent la majorité de la variabilité des données et on écarte les autres. Cela permet de réduire la dimensionnalité des données.

Exercice 11 : La PCA est-elle supervisée ou non supervisée ? Est-elle adaptée aux tâches de régression ou de classification ?

**Elle est non supervisée car on n'utilise pas les labels
Utilisable en régression et classification**

Si nous disposons de N exemples de données $\mathbf{x}_{d \times 1}$, la matrice de covariance $\mathbf{C}_{d \times d}$ est calculée comme suit :


$$\mathbf{C} = \begin{bmatrix} \text{var}(x_1) & \text{cov}(x_1, x_2) \cdots \text{cov}(x_1, x_d) \\ \text{cov}(x_2, x_1) & \text{var}(x_2) & \cdots \text{cov}(x_2, x_d) \\ \vdots & \vdots & \ddots & \vdots \\ \text{cov}(x_d, x_1) & \text{cov}(x_d, x_2) \cdots \text{var}(x_d) \end{bmatrix}$$

où

$$\text{var}(x_j) = \frac{1}{N} \sum_{i=1}^N (x_{ij} - \bar{x}_j)^2$$


$$\text{cov}(x_j, x_k) = \frac{1}{N} \sum_{i=1}^N (x_{ij} - \bar{x}_j)(x_{ik} - \bar{x}_k)$$

où x_{ij} représente la j ème caractéristique du i ème exemple de données, $\bar{x}_j$ représente la moyenne de la j ème caractéristique.




Un ensemble de données tridimensionnel (avec 4 classes). Les flèches rouge, bleue et verte indiquent respectivement la direction des première, deuxième et troisième composantes principales.

Dimension réduite de 3 à 2 en utilisant PCA.



12/2025


Exercice 12 : Que pensez-vous de la performance du PDG dans ce cas, lorsque la dimension est réduite de 2 à 1 ?



11/12/2025

Analyse discriminante linéaire (*LDA*)

Exercice 13 : Dans quel ensemble de données les données sont-elles mieux séparables ? Et pourquoi ? (Expliquez cela en termes de distance entre les classes et de variabilité au sein d'une



variance diminué = les points sont plus compacts (c'est mieux)

Réduction de caractéristiques

Analyse discriminante linéaire de Fisher (Fisher's linear discriminant analysis) (LDA)

Pour obtenir une mesure globale de la distance entre différentes classes (en prenant en compte toutes les caractéristiques), on peut définir la **matrice de dispersion inter-classes** comme suit :

$$S_b = \sum_{i=1}^C N_i (\mu_i - \mu_0) (\mu_i - \mu_0)^T$$

où

- C est le nombre de classes,
- N_i est le nombre d'exemples de la classe i ,
- μ_i est le vecteur moyen des caractéristiques de la classe i (calculé à partir de tous les exemples d'entraînement de cette classe),
- μ_0 est le vecteur moyen global, calculé sur l'ensemble des exemples d'apprentissage de toutes les classes.

Pour obtenir une mesure globale de la variabilité intraclasse (en tenant compte de toutes les caractéristiques), la matrice de dispersion intraclasse peut être définie comme suit :

$$S_w = \sum_{i=1}^C \sum_{j=1}^{N_i} (\mathbf{x}_{ij} - \mu_i) (\mathbf{x}_{ij} - \mu_i)^T$$

Où

- $\mathbf{x}_{ij}$ est le j -iem exemple de la classe i

Une mesure globale de la qualité de la séparation entre différentes classes peut être obtenue par le rapport suivant :

$$J = \frac{\text{trace}\{S_b\}}{\text{trace}\{S_w\}}$$

Ce rapport J doit être **maximisé** pour obtenir la meilleure séparation possible entre les classes.

Exercice 14 : La LDA est-elle supervisée ou non supervisée ? Est-elle adaptée aux tâches de régression ou de classification ?


La Linear Discriminant Analysis (LDA) est une méthode supervisée car elle nécessite des données étiquetées (avec des classes connues) pour apprendre. Elle est conçue spécifiquement pour les tâches de classification.

Extraction de caractéristiques à l'aide de réseaux neuronaux

Chaque couche d'un réseau de neurones à propagation avant (feed-forward) effectue une transformation non linéaire des données. Cette transformation peut être considérée comme une forme d'extraction de caractéristiques, où une entrée de dimension d est transformée en une nouvelle représentation de dimension d' .

Comment réduire la dimension d'entrée à l'aide d'un NN ?

En utilisant moins de neurones que le nombre de caractéristiques d'entrée dans la couche cachée.



Inputs

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_d \end{bmatrix}$$

First hidden layer's output

$$\mathbf{y} = f(\mathbf{W}^T \mathbf{x}) = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_{d'} \end{bmatrix}$$

Autoencoders

Un autoencodeur est un type de réseau de neurones artificiel utilisé pour apprendre des représentations efficaces de plus faible dimension (encodage) à partir de données non étiquetées, ce qui en fait une méthode d'apprentissage non supervisé.

L'encodage est validé et amélioré en essayant de reconstruire l'entrée initiale à partir de la représentation encodée.


Un autoencodeur se compose de deux parties principales :

- Un réseau encodeur (à propagation avant), qui projette les données d'entrée dans un espace latent, souvent appelé le code.
- Un réseau décodeur (à propagation avant), qui tente de reconstruire l'entrée à partir du code..

Qu'est-ce que la sortie désirée ?

Quel type de fonction de coût peut-on utiliser ? et pourquoi ?

AE est-il supervisé ou non supervisé ? et pourquoi ?



<https://www.assemblyai.com/blog/introduction-to-variational-autoencoders-using-keras/>

Reconnaissance des émotions à partir de l'EEG

Nous voulons concevoir un autoencodeur pour extraire les caractéristiques des données EEG multicanal (l'EEG est généralement enregistré sur plusieurs canaux, parfois jusqu'à 256) et utiliser un RNN pour modéliser les modèles et détecter l'état émotionnel d'un individu.

Exercice 15 : Examinez ce cadre et expliquez comment il fonctionne.

