


Cours par Mohamad Forouzanfar

L'IA DANS LES SOINS DE SANTÉ

GTS880

Sujets spéciaux en technologies de la santé



Cours 11

CLASSIFICATION DES DONNÉES À L'AIDE DE L'APPRENTISSAGE AUTOMATIQUE CLASSIQUE

Rappel

L'EXAMEN INTRA 2 : SEMAINE 12, LE 26 NOVEMBRE.

PRÉSENTATION DU PROJET : SEMAINE 13, LE 3 DÉCEMBRE

ÉVALUATION DU COURS

Objectifs

- Se familiariser avec les techniques statistiques de classification des modèles
- Apprendre l'application des techniques de classification statistique des modèles aux problèmes liés aux soins de santé

CLASSIFICATION

Classification et frontières de classes

Nous disposons de **vecteurs de caractéristiques** $\mathbf{x} = [x_1, x_2, \dots, x_d]^T$ et de leurs **étiquettes de classe** correspondantes. Notre objectif est de concevoir des techniques capables de **caractériser les frontières qui séparent ces classes**.


La classification est étroitement liée à la régression, où nous concevons des fonctions continues reliant les caractéristiques aux sorties.

- **Régression** : la sortie est une **fonction continue** des entrées.
- **Classification** : la sortie est l'**assignation** des entrées à des **groupes** ou **classes discrètes**.

On peut dire que la classification est une version discrète de la régression.

Note Terminologique :

- Dans l'apprentissage supervisé (avec étiquettes), les groupes sont nommés **classes** (e.g., Classe A, Classe B).
- Dans l'apprentissage non supervisé (sans étiquettes), les groupes découverts sont nommés **clusters** (**grappes**).



Nous recherchons des fonctions discriminantes et décisionnelles qui séparent les classes.

@Rangayyan, Rangaraj M. Biomedical signal analysis. John Wiley & Sons, 2015.

Classification linéaire

En général, une fonction discriminante ou décisionnelle linéaire peut être représentée comme suit :

$$d(x) = w_0 + w_1x_1 + w_2x_2 + \dots + w_dx_d = \mathbf{w}^T \mathbf{x}$$

où $\mathbf{x} = [1, x_1, x_2, \dots, x_d, 1]^T$ est le vecteur de caractéristiques augmenté par l'ajout d'un élément supplémentaire (1), and $\mathbf{w} = [w_0, w_1, w_2, \dots, w_d]^T$ est son vecteur de poids correspondant.

Notez que $\mathbf{w}^T \mathbf{x} = 0$ représente l'hyperplan de décision. (en 2D, il s'agit d'une ligne)

Une classification de modèles à deux classes peut alors être effectuée comme suit :

$$d(x) = \mathbf{w}^T \mathbf{x} = \begin{cases} > 0 & \text{if } \mathbf{x} \in C_1 \\ \leq 0 & \text{if } \mathbf{x} \in C_2 \end{cases}$$

où C_1 et C_2 représentent les deux classes.

Classification multiclass :

Dans le cas d'une classification de modèles de classe M (un contre tous), nous avons besoin de M vecteurs de poids et de M fonctions de décision :

$$d_i(x) = \mathbf{w}_i^T \mathbf{x} = \begin{cases} > 0 & \text{if } \mathbf{x} \in C_i, \\ \leq 0 & \text{otherwise} \end{cases}$$

pour $i = 1, 2, \dots, M$, où $\mathbf{w}_i = [w_{i0}, w_{i1}, w_{i2}, \dots, w_{id}]^T$ est le vecteur de poids pour la classe C_i .


Exemples de classificateurs linéaires :

- Régression logistique
- Machine à vecteurs de support linéaire (SVM Linéaire)
- Perceptron simple (un réseau sans couche cachée, constitué d'un seul neurone de sortie qui utilise une fonction d'activation par seuil (ou échelon))


Le signal **VAG** (VibroAcoustographie du Genou) a été enregistré à l'aide d'un **accéléromètre** placé au niveau de la rotule (mi-patella) du genou. L'enregistrement a eu lieu pendant que le sujet effectuait un mouvement de la jambe sur une amplitude angulaire approximative de 135° (flexion quasi-complète) à 0° (extension complète), puis de retour à 135° , le tout en 4 secondes.

La première moitié de chaque signal VAG correspond à l'**extension** de la jambe, et la seconde moitié correspond à sa **flexion**. Les signaux VAG ont été préfiltrés (de 10 Hz à 1 kHz) et numérisés à une fréquence d'échantillonnage de 2 kHz.

Signal VAG d'un sujet normal (a)
et d'un sujet présentant une
pathologie du genou (b).



(a)



(b)

Problème

Analyser le signal
vibroarthrogramme (VAG)

Classifier les modèles normaux
et anormaux à partir des
caractéristiques du signal VAG

Les caractéristiques extraites
utilisées comprenaient les «
facteurs de forme » FF1 et FF2,
correspondant à l'extension et à
la flexion. Donc, $\mathbf{x} = [\text{FF1},$
 $\text{FF2}]^T$. Le facteur de forme est
une mesure de la complexité du
signal (cours 10).


Analyser le signal vibroarthrogramme (VAG)

Le classificateur linéaire n'a pu classer correctement que 19 signaux anormaux sur 38 et 40 signaux normaux sur 51, ce qui donne une aire sous la courbe caractéristique de fonctionnement (ROC) de 0,72.

D'autres caractéristiques ont également été ajoutées à l'analyse (entropie (H), asymétrie (S) et kurtosis (K)), aucune amélioration n'a été obtenue.

Grâce à un réseau neuronal, la surface sous la courbe ROC la plus élevée, soit 0,82, a été atteinte.

Dans un autre travail, un réseau neuronal utilisant une nouvelle caractéristique, « *turns count* », a obtenu de meilleures performances de classification avec une surface sous la courbe ROC de 0,92.



Classification d'un ensemble de données de 89 signaux VAG à l'aide de la LDA. Les cercles représentent des échantillons normaux du vecteur de caractéristiques $[FF1, FF2]^T$ et les croix représentent des échantillons anormaux. La ligne droite est la fonction de décision linéaire, donnée par **$0,0058 \text{ FF1} - 0,0010 \text{ FF2} - 0,0192 = 0$** .


Régression logistique

La **régression logistique** est un algorithme de **classification linéaire** qui étend le modèle de régression linéaire. L'idée centrale est de projeter le résultat de la régression linéaire sur une valeur de **probabilité** comprise entre **0** et **1**.

Cette transformation s'effectue à l'aide de la **fonction sigmoïde** (ou fonction logistique). Pour un vecteur de caractéristiques $\mathbf{x}$ à d dimensions :

$$P(Y = 1|\mathbf{x}) = \frac{1}{1 + \exp[-(w_0 + w_1x_1 + \dots + w_dx_d)]}$$

Les paramètres du modèle sont généralement trouvés en minimisant la perte entropie croisée binaire.



La fonction logistique standard


La règle du plus proche voisin

Considérons que nous avons N exemples d'apprentissage avec des vecteurs de caractéristiques de d dimension $\{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_N\}$ et que nous connaissons leurs étiquettes de classe réelles, chaque modèle appartenant à une classe parmi M classes : $\{C_1, C_2, \dots, C_M\}$.

Nous obtenons alors un nouveau vecteur de caractéristiques $\mathbf{x}_{\text{New}}$ dont la classe doit être déterminée.

Exercice 1: En considérant la classe des points de données les plus proches de $\mathbf{x}_{\text{New}}$ (en vert) déterminez la classe de $\mathbf{x}_{\text{New}}$

1. Considérez le point de données le plus proche.
2. Considérez les trois points de données les plus proches.
3. Considérez les cinq points de données les plus proches.



La règle du plus proche voisin

Considérons que nous avons N exemples d'apprentissage avec des vecteurs de caractéristiques de d dimension $\{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_N\}$ et que nous connaissons leurs étiquettes de classe réelles, chaque modèle appartenant à une classe parmi M classes : $\{C_1, C_2, \dots, C_M\}$.

Nous obtenons alors un nouveau vecteur de caractéristiques $\mathbf{x}_{\text{New}}$ dont la classe doit être déterminée.

Une métrique de distance $D(\mathbf{x}_i, \mathbf{x}_{\text{New}})$ peut être définie entre le vecteur $\mathbf{x}_{\text{New}}$ et chaque exemple $\mathbf{x}_i$.


La règle du plus proche voisin attribue $\mathbf{x}_{\text{new}}$ à la classe de l'exemple le plus proche de $\mathbf{x}_{\text{new}}$ dans l'ensemble d'entraînement :

$$\mathbf{x}_{\text{new}} \in C_k \quad \text{si} \quad k = \arg \min_{i \in \{1, 2, \dots, N\}} D(\mathbf{x}_i, \mathbf{x}_{\text{new}})$$

La métrique de distance généralement utilisée est la norme 2 (L2), également appelée distance euclidienne :

$$D = \|\mathbf{x}_i - \mathbf{x}_{\text{new}}\| = \sqrt{(\mathbf{x}_i - \mathbf{x}_{\text{new}})^T (\mathbf{x}_i - \mathbf{x}_{\text{new}})}$$

pour $i = 1$ à M .



La Faiblesse du Plus Proche Voisin

Si le point de données le plus proche de $\mathbf{x}_{\text{new}}$ est bruité ou aberrant (outlier), la classification sera incorrecte.

La Solution : k-Plus Proches Voisins (k-NN)


- Il cherche les k exemples d'entraînement les plus proches de la nouvelle observation.
- Il effectue un vote majoritaire parmi leurs étiquettes.
- L'observation est affectée à la classe la plus fréquente.

Paramètres d'entraînement : aucun (Nous n'avons pas de phase d'entraînement !)

Hyperparamètre : k

Machines à vecteurs de support (SVM)

Exercice 2 : Montrez le meilleur classificateur linéaire (ligne) qui sépare ces deux classes. Quels points de données avez-vous pris en compte dans votre solution ?




Machines à vecteurs de support (SVM)

Tous les hyperplans qui séparent les classes dans les données d'apprentissage ne sont pas nécessairement les hyperplans optimaux.

Le **SVM** cherche l'hyperplan qui assure la **marge** de séparation la plus large entre les classes.

Cette marge maximise la distance entre la frontière de décision et les points d'entraînement les plus proches (**vecteurs de support**). La frontière peut être une ligne (2D) ou un hyperplan (nD).




Exemples de trois hyperplans pour un problème de classification à deux classes. H1 ne peut pas séparer les classes, H2 sépare les classes avec une marge réduite, et H3 les sépare avec une marge maximale.

Machines à vecteurs de support (SVM) (linéaires)

Une SVM est une méthode de classification qui trouve la meilleure frontière, appelée un **hyperplan**, pour séparer les différentes classes de données.

Elle s'assure que la distance, ou **marge**, entre l'hyperplan et les points de données les plus proches de chaque classe est aussi **grande que possible**.

Les points de données les plus proches qui définissent cette marge sont appelés les **vecteurs de support** (ou *support vectors*). L'hyperplan optimal est celui qui se trouve exactement au milieu de cette marge, représenté par $\mathbf{w}^T \mathbf{x} + b = 0$.



SVM maximum-margin hyperplane and margins two-class classification problem. Samples on the margin are called the “support vectors”.

@wikipedia

SVM linéaire

Considérez un ensemble d'apprentissage de N exemples, $(\mathbf{x}_1, z_1), (\mathbf{x}_2, z_2), \dots, (\mathbf{x}_N, z_N)$, où $\mathbf{x}_i$ est le vecteur de caractéristiques et $z_i = \{-1, 1\}$ est son étiquette.


En supposant que les données **sont linéairement séparables**, on cherche à définir **deux hyperplans marginaux parallèles** qui maximisent la distance entre eux (la **marge**) tout en séparant les deux classes. L'hyperplan de séparation optimal, situé exactement entre les deux hyperplans marginaux, est donné par :

$$\mathbf{w}^T \mathbf{x} + b = 0$$

Les deux hyperplans marginaux (les plus proches des données) sont définis par :

Hyperplan supérieur : $\mathbf{w}^T \mathbf{x} + b = 1$

Hyperplan inférieur : $\mathbf{w}^T \mathbf{x} + b = -1$



SVM linéaire

Géométriquement, la distance entre ces deux hyperplans marginaux (la **marge**) est donnée par $2/\|\mathbf{w}\|$ (Sans preuve)

Objectif d'Optimisation :


Pour maximiser cette distance, il faut donc minimiser la norme euclidienne du vecteur de poids $\mathbf{w}$: $\|\mathbf{w}\|$.

Contraintes :

De plus, une **contrainte** doit être ajoutée pour s'assurer qu'aucun point de donnée ne tombe à l'intérieur de la marge (entre les deux hyperplans) :

Si l'étiquette $z_i = 1$ (classe positive), le point $\mathbf{x}_i$ doit satisfaire : $\mathbf{w}^T \mathbf{x}_i + b \geq 1$,

Si l'étiquette $z_i = -1$ (classe négative), le point $\mathbf{x}_i$ doit satisfaire : $\mathbf{w}^T \mathbf{x}_i + b \leq -1$




SVM linéaire

- La solution pratique à ce problème d'optimisation est souvent obtenue en utilisant des méthodes de **descente de gradient stochastique** (ou similaires) via un algorithme itératif, tel que **Pegasos** (qui n'est pas l'objet de ce cours).
- On peut démontrer que les paramètres w et b optimaux sont uniquement déterminés par les vecteurs de support (x_i qui se trouvent sur les marges), et non par l'ensemble des autres points de données.

Une demo :

<https://greitemann.dev/svm-demo>

(Fixer le paramètre ν à zéro pour une SVM dure (SVM classique).)



Extensions de la SVM

SVM à marge souple :

Lorsque les données sont **bruitées**, nous modifions la fonction de coût en ajoutant des **termes de pénalité** ξ_i pour les points qui ne satisfont pas la contrainte. La pénalité est la distance signée de ces points bruyants par rapport à leur hyperplan marginal correspondant :

$$\mathbf{w}^T \mathbf{w} + C \sum_{i=1}^N \xi_i(\mathbf{w})$$


C un **hyperparamètre** contrôle l'impact des termes de pénalité ξ_i

SVM Non-Linéaire (Kernel SVM) :


Si les données **ne sont pas séparables linéairement**, nous utilisons une fonction noyau (Φ) appropriée pour les projeter dans un espace de dimension supérieure, les rendant ainsi linéairement séparables.

Le choix du noyau (comme linéaire, polynomial ou Gaussien) est un **hyperparamètre** essentiel.

SVM à marge souple :



SVM Non-Linéaire (Kernel SVM) :



Extensions de la SVM


Exercice 3 : Quels sont les paramètres apprenables du SVM et quels sont les hyperparamètres ?

Paramètres Apprenables du SVM (Tous Types) :
 w et b


Hyperparamètres du SVM (Par Type)

- **Linéaire** : Aucun
- **Souple** : C
- **Non-Linéaire** : C , Noyau et ses paramètres.

SVM à marge souple :



SVM Non-Linéaire (Kernel SVM) :



Fonctions de Vraisemblance et Décisions Statistiques

Lorsque les **Fonctions de Densité de Probabilité (PDF)** des caractéristiques de différentes classes sont disponibles (**connues ou estimées**), des **fonctions de décision optimales** peuvent être conçues en s'appuyant sur la **théorie de la décision statistique**.

Une approche courante consiste à modéliser la distribution des caractéristiques pour chaque classe par une **PDF Gaussienne** (ou Loi **Normale**), dont les paramètres de moyenne (μ) et de variance (σ) sont estimés à partir des données d'apprentissage :

$$p(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp \left[-\frac{1}{2} \left(\frac{x - \mu}{\sigma} \right)^2 \right]$$

Termes Clés :

Probabilité a priori $P(C_i)$: La probabilité inconditionnelle qu'un exemple appartienne à la classe C_i ($i = 1, 2, \dots, M$) avant toute observation.

Probabilité a posteriori $P(C_i | \mathbf{x})$: La probabilité conditionnelle qu'un exemple observé $\mathbf{x}$ provient de C_i .

La perte L_{ij} : Le coût ou la **perte encourue** si un classifieur assigne l'exemple à la classe C_j alors qu'il appartient en réalité à la classe C_i . ($L_{ii} = 0$)

Le Classifieur de Bayes (Règle de Décision Optimale) :

Pour une observation $\mathbf{x}$, la **perte conditionnelle** d'assigner $\mathbf{x}$ à C_j peut être représentée comme la somme des pertes de classification pondérées par les probabilités a posteriori de toutes les classes :

$$R_j(\mathbf{x}) = \sum_{i=1}^M L_{ij} P(C_i | \mathbf{x})$$

Un classifieur qui calcule ce risque $R_j(\mathbf{x})$ pour chaque classe C_j et assigne $\mathbf{x}$ à la classe présentant le risque conditionnel minimal est appelé le **Classifieur de Bayes**.

Fonctions de Vraisemblance et Décisions Statistiques

Pour calculer la probabilité d'appartenance à chaque classe, $P(C_i|\mathbf{x})$, nous utilisons la **Formule de Bayes** :

$$P(C_i|\mathbf{x}) = \frac{P(C_i)p(\mathbf{x}|C_i)}{p(\mathbf{x})}$$

- $p(\mathbf{x}|C_i)$ est la **fonction de vraisemblance** de la classe C_i (*Likelihood*). Elle représente la densité de probabilité d'observer $\mathbf{x}$ sachant que l'exemple appartient à la classe C_i .
- $p(\mathbf{x})$ est la densité de probabilité marginale de $\mathbf{x}$ qui ne dépend pas de la classe : $p(\mathbf{x}) = \sum_{j=1}^K P(\mathbf{x}|c_j) P(c_j)$.

En substituant la formule de Bayes dans la formule du risque conditionnel $R_j(\mathbf{x})$, le risque peut s'écrire :

$$R_j(\mathbf{x}) = \frac{1}{p(\mathbf{x})} \sum_{i=1}^M L_{ij} P(C_i)p(\mathbf{x}|C_i)$$

Termes Clés :

Probabilité a priori $P(C_i)$: La probabilité inconditionnelle qu'un exemple appartienne à la classe C_i ($i = 1, 2, \dots, M$) avant toute observation.

Probabilité a posteriori $P(C_i|\mathbf{x})$: La probabilité conditionnelle qu'un exemple observé $\mathbf{x}$ provient de C_i .

La perte L_{ij} : Le coût ou la **perte encourue** si un classifieur assigne l'exemple à la classe C_j alors qu'il appartient en réalité à la classe C_i . ($L_{ii} = 0$)

Le Classifieur de Bayes (Règle de Décision Optimale) :

Pour une observation $\mathbf{x}$, la **perte conditionnelle** d'assigner $\mathbf{x}$ à C_j peut être représentée comme la somme des pertes de classification pondérées par les probabilités a posteriori de toutes les classes :

$$R_j(\mathbf{x}) = \sum_{i=1}^M L_{ij} P(C_i|\mathbf{x})$$

Un classifieur qui calcule ce risque $R_j(\mathbf{x})$ pour chaque classe C_j et assigne $\mathbf{x}$ à la classe présentant le risque conditionnel minimal est appelé le **Classifieur de Bayes**.

Fonctions de Vraisemblance et Décisions Statistiques

Pour calculer la probabilité d'appartenance à chaque classe, $P(C_i|\mathbf{x})$, nous utilisons la **Formule de Bayes** :

$$P(C_i|\mathbf{x}) = \frac{P(C_i)p(\mathbf{x}|C_i)}{p(\mathbf{x})}$$

- $p(\mathbf{x}|C_i)$ est la **fonction de vraisemblance** de la classe C_i (*Likelihood*). Elle représente la densité de probabilité d'observer $\mathbf{x}$ sachant que l'exemple appartient à la classe C_i .
- $p(\mathbf{x})$ est la densité de probabilité marginale de $\mathbf{x}$ qui ne dépend pas de la classe : $p(\mathbf{x}) = \sum_{j=1}^K P(\mathbf{x}|c_j) P(c_j)$.

En substituant la formule de Bayes dans la formule du risque conditionnel $R_j(\mathbf{x})$, le risque peut s'écrire :

$$R_j(\mathbf{x}) = \frac{1}{p(\mathbf{x})} \sum_{i=1}^M L_{ij} P(C_i)p(\mathbf{x}|C_i)$$

Règle de Décision de Bayes Simplifiée

La **Probabilité *a posteriori*** $P(C_i|\mathbf{x})$ étant calculée avec la formule de Bayes, le processus de décision est direct :

- Nous calculons le **risque conditionnel** $R_j(\mathbf{x})$ pour chaque classe C_j .
- L'observation $\mathbf{x}$ est assignée à la classe C_j qui présente le **risque le plus faible** $R_j(\mathbf{x})$.

Cas de la Perte Minimale (Classifieur MAP)

Dans le cas fréquent où l'on suppose que toutes les erreurs ont la même perte unitaire $L_{ij} = 1$ si $i \neq j$ et $L_{ii} = 0$), le Classifieur de Bayes se simplifie au **Classifieur du Maximum *a Posteriori* (MAP)** (Pour la preuve, consultez le livre de Rangayan):

$$d_i(\mathbf{x}) = P(C_i)p(\mathbf{x}|C_i), \quad i = 1, 2, \dots, M$$

où un motif $\mathbf{x}$ est attribué à la classe C_i si $d_i(\mathbf{x}) > d_j(\mathbf{x}) \quad \forall j \neq i$ pour ce motif.

Si les caractéristiques (d éléments du vecteur $\mathbf{x}$) sont **indépendantes**, la classification est simplifiée en un **classificateur naïf de Bayes** :

$$d_i(\mathbf{x}) = P(C_i) \prod_{j=1}^d p(x_j|C_i)$$

Fonctions de Vraisemblance et Décisions Statistiques

Si nous supposons une distribution **gaussienne** pour les fonctions de vraisemblance, les fonctions de décision peuvent être encore simplifiées :

$$d_i(\mathbf{x}) = \ln P(C_i) - \frac{1}{2} \ln |\mathbf{C}_i| - \frac{1}{2} [(\mathbf{x} - \mathbf{m}_i)^T \mathbf{C}_i^{-1} (\mathbf{x} - \mathbf{m}_i)],$$
$$i = 1, 2, \dots, M$$

où

$$\mathbf{m}_i = E_i[\mathbf{x}],$$
$$\mathbf{C}_i = E_i[(\mathbf{x} - \mathbf{m}_i)(\mathbf{x} - \mathbf{m}_i)^T].$$

Règle de Décision de Bayes Simplifiée

La **Probabilité *a posteriori*** $P(C_i|\mathbf{x})$ étant calculée avec la formule de Bayes, le processus de décision est direct :

- Nous calculons le **risque conditionnel** $R_j(\mathbf{x})$ pour chaque classe C_j .
- L'observation $\mathbf{x}$ est assignée à la classe C_j qui présente le **risque le plus faible** $R_j(\mathbf{x})$.

Cas de la Perte Minimale (Classifieur MAP)


Dans le cas fréquent où l'on suppose que toutes les erreurs ont la même perte unitaire $L_{ij} = 1$ si $i \neq j$ et $L_{ii} = 0$), le Classifieur de Bayes se simplifie au **Classifieur du Maximum *a Posteriori* (MAP)** (Pour la preuve, consultez le livre de Rangayan) :

$$d_i(\mathbf{x}) = P(C_i)p(\mathbf{x}|C_i), \quad i = 1, 2, \dots, M$$

où un motif $\mathbf{x}$ est attribué à la classe C_i si $d_i(\mathbf{x}) > d_j(\mathbf{x}) \quad \forall j \neq i$ pour ce motif.

Si les caractéristiques (éléments du vecteur $\mathbf{x}$) sont **indépendantes**, la classification est simplifiée en un **classificateur naïf de Bayes** :

$$d_i(\mathbf{x}) = P(C_i) \prod_{j=1}^d p(x_j|C_i)$$



Signaux ECG de 10 secondes d'un homme de 65 ans présentant des extrasystoles ventriculaires (PVC). Chaque battement a été manuellement étiqueté comme normal « o » ou extrasystoles ventriculaires « x ». La fréquence d'échantillonnage est de 200 Hz.

Détection des battements ECG normaux et ectopiques

Battement Ectopique (ou Extrasystole) : Un battement supplémentaire ou prématuré provenant de n'importe quel emplacement anormal dans le cœur.


PVC (Contraction Ventriculaire Prématurée) : Un battement supplémentaire ou prématuré provenant spécifiquement des ventricules.

Chaîne de Pré-Traitement du Signal et de Classification de Battements Cardiaques

1. **Préparation du Signal** : Le signal a d'abord été filtré (passe-bas de Butterworth, 70 Hz) pour éliminer le bruit.
2. **Détection et Segmentation des Battements** : L'algorithme de Pan-Tompkins a été utilisé pour détecter chaque battement. Chaque battement (portion QRS-T) a ensuite été segmenté (intervalle de -160 ms à +240 ms par rapport au pic R) et normalisé (soustraction de la moyenne et division par la valeur maximale).
3. **Extraction et Normalisation des Caractéristiques** : La ligne de base de chaque battement a été soustraite avant de redresser le signal (valeur absolue). La caractéristique QRSTA (somme des valeurs redressées multipliée par l'intervalle d'échantillonnage) a été calculée. Le vecteur de caractéristiques $[QRSTA, FF]^T$ a été créé, et ses valeurs ont été normalisées en utilisant la moyenne et l'écart-type de l'ensemble d'apprentissage.
4. **Classification** : En utilisant uniquement l'ensemble d'apprentissage (123 battements normaux, 39 PVC), les fonctions de probabilité conditionnelle et a posteriori unidimensionnelles ont été estimées pour développer le Classifieur de Bayes.


Détection des
battements ECG
normaux et
ectopiques

Fonctions de vraisemblance et de probabilité a posteriori estimées pour les caractéristiques de l'ensemble d'apprentissage des signaux ECG normaux « ° » et des PVC « × ».



On a supposé des **distributions gaussiennes** pour les probabilités conditionnelles (vraisemblances).


Les probabilités a priori $P(C_i)$ utilisant les deux classes ont été supposées égales.



Détection des battements ECG normaux et ectopiques

Exercice 4 :
Identifiez les probabilités conditionnelles de $\mathbf{x}$ (likelihoods) et les probabilités a posteriori.

Train data



Test data




Diagramme de dispersion
2D des vecteurs de
caractéristiques
 $[QRSTA, FF]^T$.

Les cercles représentent les
battements normaux et les
signes plus représentent les
PVC ; les symboles en
forme de losange et d'étoile
représentent les vecteurs de
classe moyens
correspondants.

Les ellipses montrent les
limites des fonctions
Gaussiennes 2D estimées à
 σ , 2σ et 3σ pour chaque
classe. Le contour elliptique
partiel est la **frontière de
décision Bayésienne**.

Détection des battements ECG normaux et ectopiques

REGROUPEMENT (CLUSTERING)

Regroupement (Clustering)


Le K-means (K-moyennes)

Le **K-means** est une méthode pour regrouper les données (**non supervisé**). Son objectif est de former des groupes (clusters) les plus compacts et homogènes possible :

1. **Initialisation** : On choisit K points de départ. Ce sont les centres de nos futurs groupes.
2. **L'affectation** : Chaque point de donnée va rejoindre le centre le plus proche de lui.
3. **La mise à jour** : Le centre de chaque groupe est déplacé pour être exactement au milieu de tous les points qui lui sont affectés.


4. **On vérifie** : Si les centres n'ont plus bougé, on a terminé. Sinon, on retourne à l'étape 2.

1ère itération




Application de la
méthode de
regroupement
(clustering) K-moyennes
à la détection des
battements ECG
normaux versus
ectopiques.

2e itération



Application de la méthode de regroupement (clustering) K-moyennes à la détection des battements ECG normaux versus ectopiques.

3e itération



Application de la méthode de regroupement (clustering) K-moyennes à la détection des battements ECG normaux versus ectopiques.